python时间序列异常检测ADTK

1. adtk简介

智能运维AIOps的数据基本上都是时间序列形式的，而异常检测告警是AIOps中重要组成部分。笔者最近在处理时间序列数据时有使用到adtk这个python库，在这里和大家做下分享。

什么是adtk?

adtk（Anomaly Detection Toolkit）是无监督异常检测的python工具包，它提供常用算法和处理函数：

- 简单有效的异常检测算法（detector）
- 异常特征加工（transformers）
- 处理流程控制（Pipe）

2. 安装

```
pip install adtk
```

3. adtk数据要求

时间序列的数据主要包括时间和相应的指标（如cpu，内存，数量等）。python中数据分析一般都是pandas的DataFrame，adtk要求输入数据的索引必须是`DatetimeIndex`。

pandas提供了时间序列的时间生成和处理方法。

- pd.date_range

```
stamps = pd.date_range("2012-10-08 18:15:05", periods=4, freq="D")
# DatetimeIndex(['2012-10-08 18:15:05', '2012-10-09 18:15:05',
#           '2012-10-10 18:15:05', '2012-10-11 18:15:05'],
#          dtype='datetime64[ns]', freq='D')
```

- pd.Timestamp

```
tmp = pd.Timestamp("2018-01-05") + pd.Timedelta("1 day")
print(tmp, tmp.timestamp(), tmp.strftime('%Y-%m-%d'))
# 2018-01-06 00:00:00 1515196800.0 2018-01-06
pd.Timestamp( tmp.timestamp(), unit='s', tz='Asia/Shanghai')
# Timestamp('2018-01-06 08:00:00+0800', tz='Asia/Shanghai')
```

- pd.to_datetime

adtk提供是`validate_series`来验证时间序列数据的有效性，如是否按时间顺序

```
import pandas as pd
from adtk.data import validate_series
from adtk.visualization import plot
df = pd.read_csv('./data/nyc_taxi.csv', index_col="timestamp", parse_dates=True)
df = validate_series(df)
plot(df)
```

	value
timestamp	
2014-07-01 00:00:00	10844
2014-07-01 00:30:00	8127
2014-07-01 01:00:00	6210
2014-07-01 01:30:00	4656
2014-07-01 02:00:00	3820

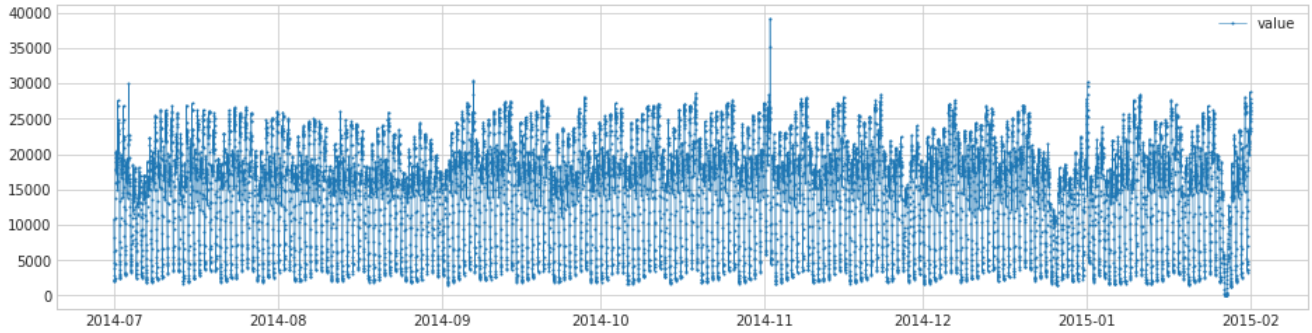

4. 异常特征加工（transformers）

adtk中`transformers`提供了许多时间序列特征加工的方法：

- 一般我们获取时间序列的特征，通常会按照时间窗口在滑动，采集时间窗口上的统计特征；
- 还有对于季节性趋势做分解，区分哪些是季节性的部分，哪些是趋势的部分
- 时间序列降维映射：对于细粒度的时间序列数据，数据量大，对于检测算法来说效率不高。降维方法能保留时间序列的主要趋势等特征同时，降低维数，提供时间效率。这个对于用CNN的方式来进行时间序列分类特别有效，adtk主要提供基于pca的降维和重构方法,主要应用于多维时间序列。

4.1 滑动窗口

atdk提供单个宽口`RollingAggregate`和2个窗口`DoubleRollingAggregate`的滑动方式。统计特征支持均值，中位数，汇总，最大值，最小值，分位数， 方差，标准差，偏度，峰度，直方图 等，`['mean', 'median', 'sum', 'min', 'max', 'quantile', 'iqr', 'idr', 'count', 'nnz', 'nunique', 'std', 'var', 'skew', 'kurt', 'hist']` 其中

- 'iqr': 是分位数 75% 和 25%差值
- 'idr': 是分位数 90% 和 10%插值
- RollingAggregate

```
import pandas as pd
from adtk.data import validate_series
from adtk.transformer import RollingAggregate
from adtk.transformer import DoubleRollingAggregate
s = pd.read_csv('./data/nyc_taxi.csv', index_col="timestamp",
parse_dates=True)
s = validate_series(s)

s_transformed = RollingAggregate(agg='quantile',agg_params={"q": [0.25,
0.75]}, window=5).transform(s)
```

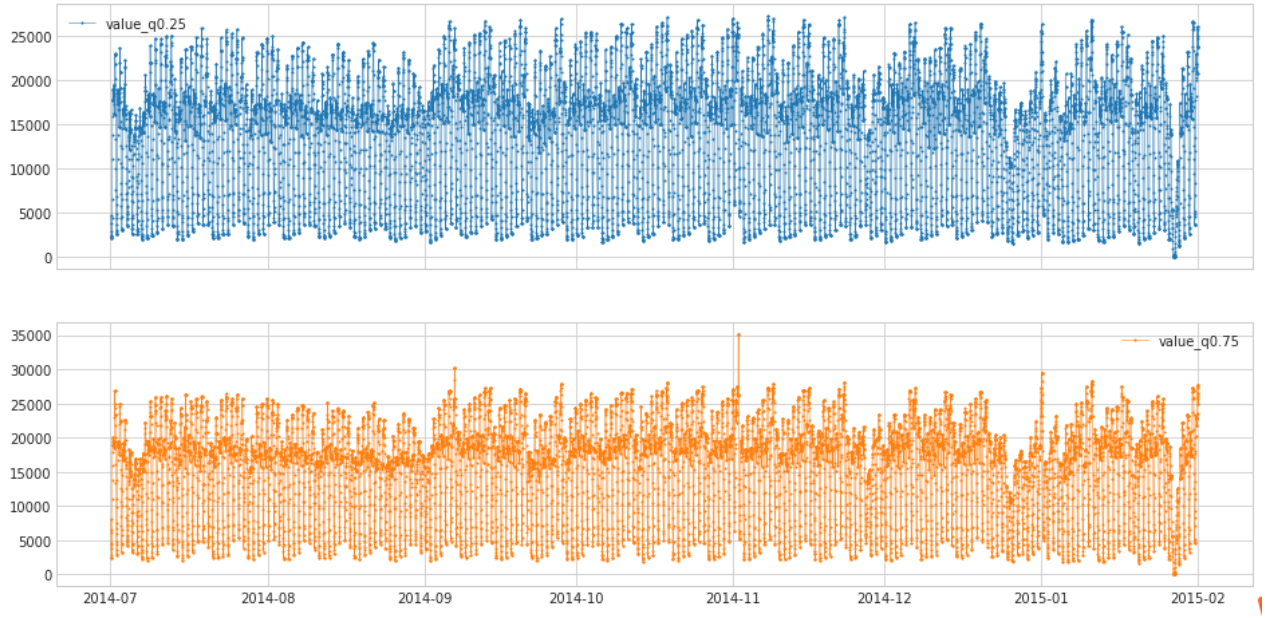

- DoubleRollingAggregate 提供了两个窗口之间统计特征的差异特征，如前5分钟和后5分钟，均值的差值等。`agg`参数和RollingAggregate中一致，新增的参数`diff`主要衡量差距的函数：
    - 'diff': 后减去前
    - 'rel_diff': Relative difference between values of aggregated metric (right minus left divided left). Only applicable if the aggregated metric is scalar.
    - 'abs_rel_diff': （后-前）/前， 相对差值
    - 'l1': l1正则
    - 'l2': l2正则

```
import pandas as pd
from adtk.data import validate_series
from adtk.transformer import DoubleRollingAggregate
s = pd.read_csv('./data/ec2_cpu_utilization_53ea38.csv',
index_col="timestamp", parse_dates=True)
s = validate_series(s)

s_transformed = DoubleRollingAggregate(
    agg="median",
    window=5,
    diff="diff").transform(s)
```

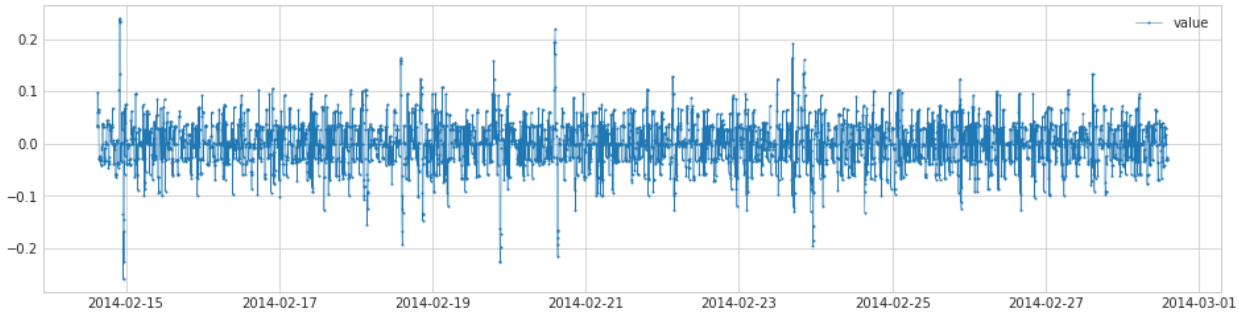

4.2 季节性拆解

时间序列可拆解成趋势性，季节性和残差部分。atdk中`ClassicSeasonalDecomposition`提供了这三个部分拆解，并移除趋势和季节性部分，返回残差部分。

- freq: 设置季节性的周期
- trend： 可以设置是否保留趋势性

```
from adtk.transformer import ClassicSeasonalDecomposition

s = pd.read_csv('./data/nyc_taxi.csv', index_col="timestamp", parse_dates=True)
s = validate_series(s)

s_transformed = ClassicSeasonalDecomposition().fit_transform(s)
```

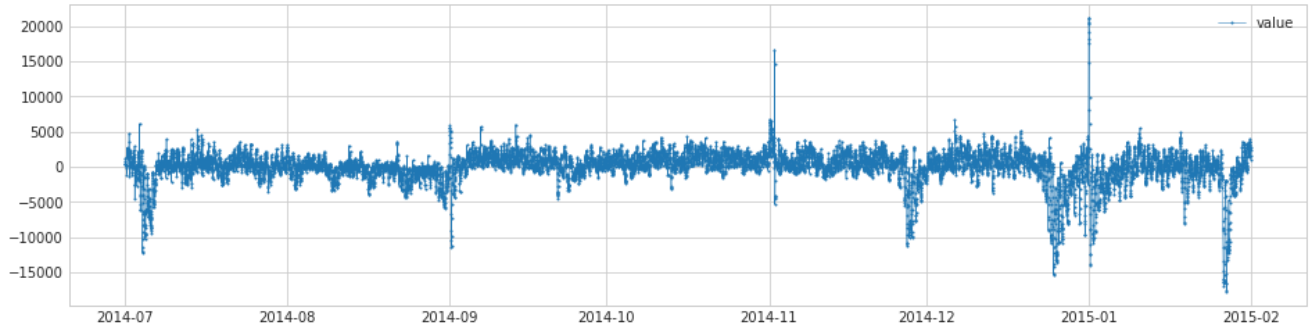


```
s_transformed = ClassicSeasonalDecomposition(trend=True).fit_transform(s)
```

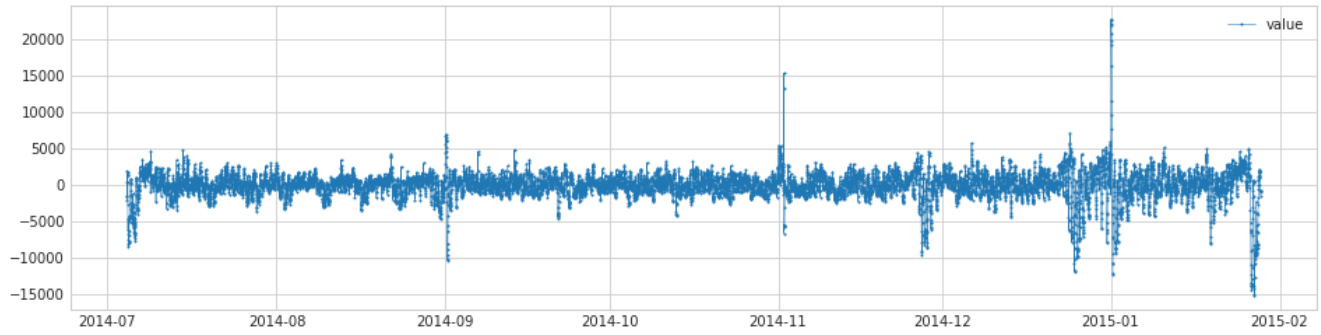

4.3 降维和重构

adtk提供的pca对数据进行降维到主成分`PcaProjection`和重构方法`PcaReconstruction`。

```
df = pd.read_csv('./data/generator.csv', index_col="Time", parse_dates=True)
df = validate_series(df)

from adtk.transformer import PcaProjection
s = PcaProjection(k=1).fit_transform(df)
plot(pd.concat([df, s], axis=1), ts_linewidth=1, ts_markersize=3, curve_group=
[("Speed (kRPM)", "Power (kW)"), "pc0"]);
```

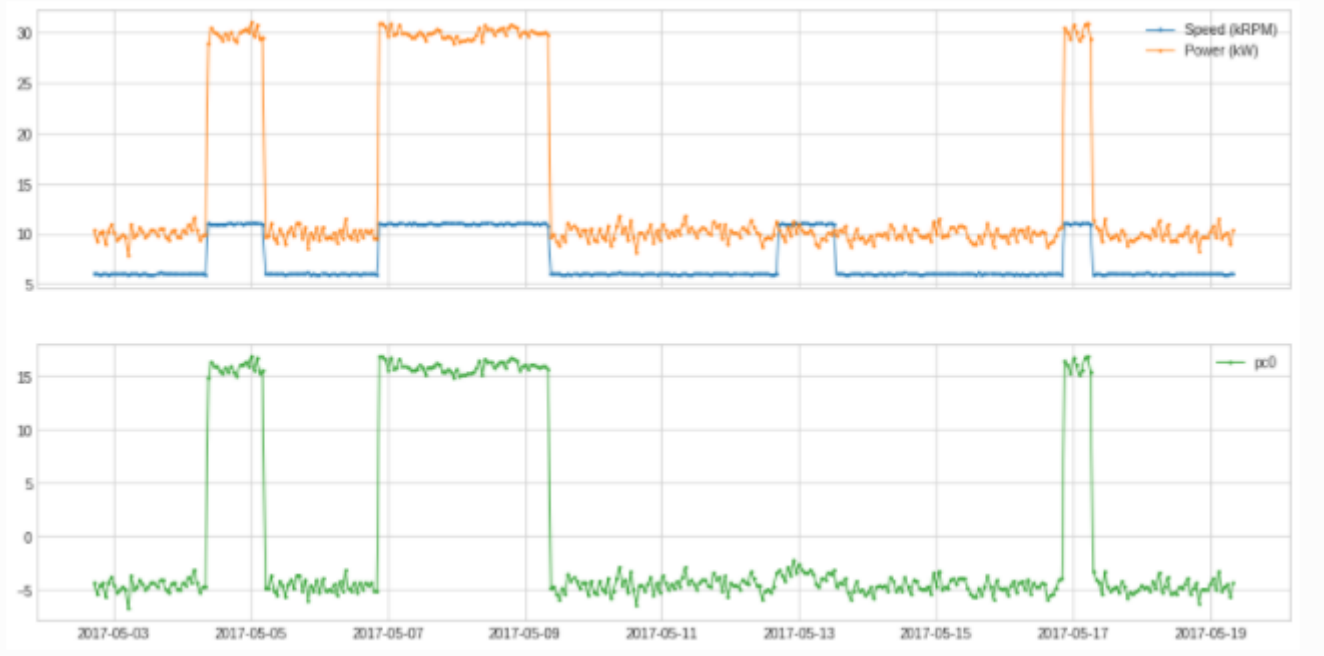


```
from adtk.transformer import PcaReconstruction
df_transformed = PcaReconstruction(k=1).fit_transform(df).rename(columns={"Speed
(kRPM)": "Speed reconstruction (kRPM)", "Power (kW)": "Power reconstruction
(kW)"})
plot(pd.concat([df, df_transformed], axis=1), ts_linewidth=1, ts_markersize=3,
curve_group=[("Speed (kRPM)", "Power (kW)"), ("Speed reconstruction (kRPM)",
"Power reconstruction (kW)")]);
../_images/notebooks_demo_99_0.png
```

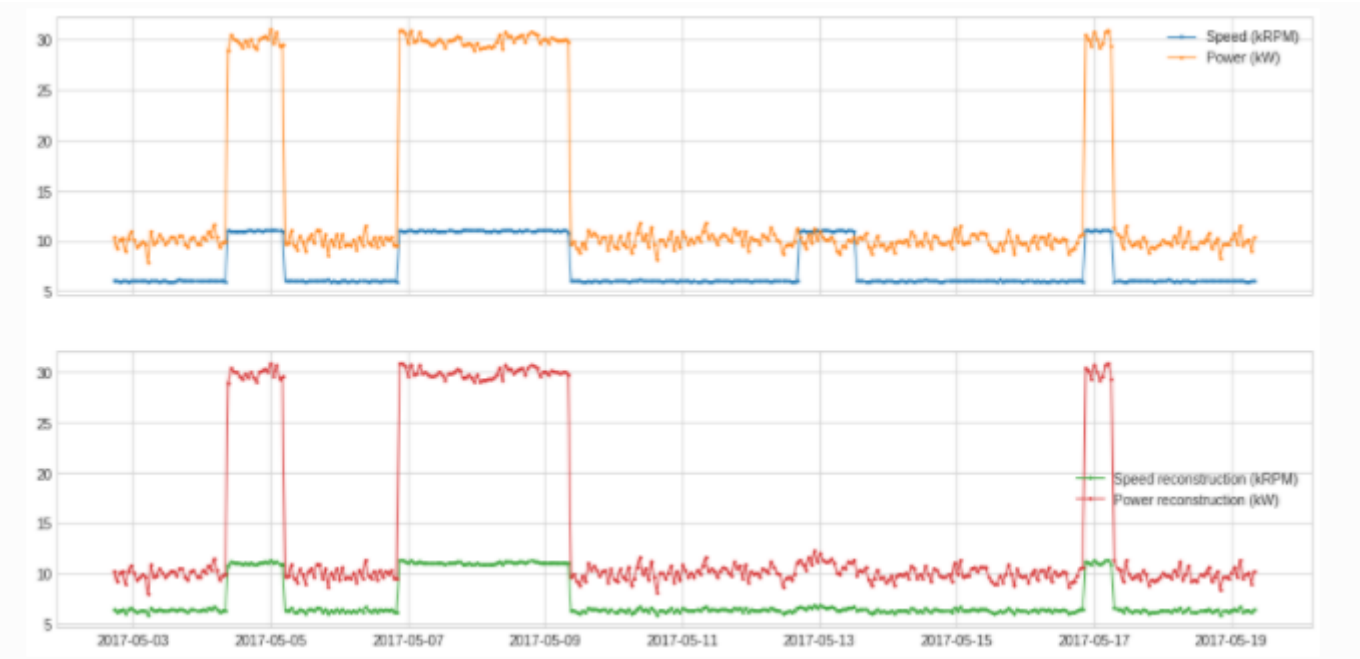

5. 异常检测算法（detector）

adtk提供的主要是无监督或者基于规则的时间序列检测算法，可以用于常规的异常检测。

- 检测离群点 离群点是和普通数据差异极大的数据点。adtk主要提供了包括 `adtk.detector.ThresholdAD` `adtk.detector.QuantileAD` `adtk.detector.InterQuartileRangeAD` `adtk.detector.GeneralizedESDTestAD`的检测算法。
  - ThresholdAD

```
adtk.detector.ThresholdAD(low=None, high=None)
参数：
low：下限，小于此值，视为异常
high：上限，大于此值，视为异常
原理：通过认为设定上下限来识别异常
总结：固定阈值算法
```

```
from adtk.detector import ThresholdAD
threshold_ad = ThresholdAD(high=30, low=15)
anomalies = threshold_ad.detect(s)
```

- QuantileAD

```
adtk.detector.QuantileAD(low=None, high=None)
参数：
low：分位下限，范围(0,1)，当low=0.25时，表示Q1
high：分位上限，范围(0,1)，当low=0.25时，表示Q3
原理：通过历史数据计算出给定low与high对应的分位值Q_low,Q_high，小于Q_low或大于Q_high，视为异常
总结：分位阈值算法
```

```
from adtk.detector import QuantileAD
quantile_ad = QuantileAD(high=0.99, low=0.01)
anomalies = quantile_ad.fit_detect(s)
```

- InterQuartileRangeAD

```
adtk.detector.InterQuartileRangeAD(c=3.0)
参数：
c：分位距的系数，用来确定上下限，可为float，也可为(float,float)
原理：
当c为float时，通过历史数据计算出 Q3+c*IQR 作为上限值，大于上限值视为异常
当c=(float1,float2)时，通过历史数据计算出 (Q1-c1*IQR, Q3+c2*IQR) 作为正常范围，不在正常范围视为异常
总结：箱线图算法
```

```
from adtk.detector import InterQuartileRangeAD
iqr_ad = InterQuartileRangeAD(c=1.5)
anomalies = iqr_ad.fit_detect(s)
```

- GeneralizedESDTestAD

```
adtk.detector.GeneralizedESDTestAD(alpha=0.05)
参数：
alpha：显著性水平 (Significance level)，alpha越小，表示识别出的异常约有把握是真异常
原理:将样本点的值与样本的均值作差后除以样本标准差，取最大值，通过t分布计算阈值，对比阈值确定异常点

计算步骤简述：
设置显著水平alpha，通常取0.05
指定离群比例h，若h=5%，则表示50各样本中存在离群点数为2
计算数据集的均值mu与标准差sigma，将所有样本与均值作差，取绝对值，再除以标准差，找出最大值，得到esd_1
在剩下的样本点中，重复步骤3，可以得到h个esd值
为每个esd值计算critical value: lambda_i (采用t分布计算)
统计每个esd是否大于lambda_i，大于的认为你是异常
```

```
from adtk.detector import GeneralizedESDTestAD
esd_ad = GeneralizedESDTestAD(alpha=0.3)
anomalies = esd_ad.fit_detect(s)
```

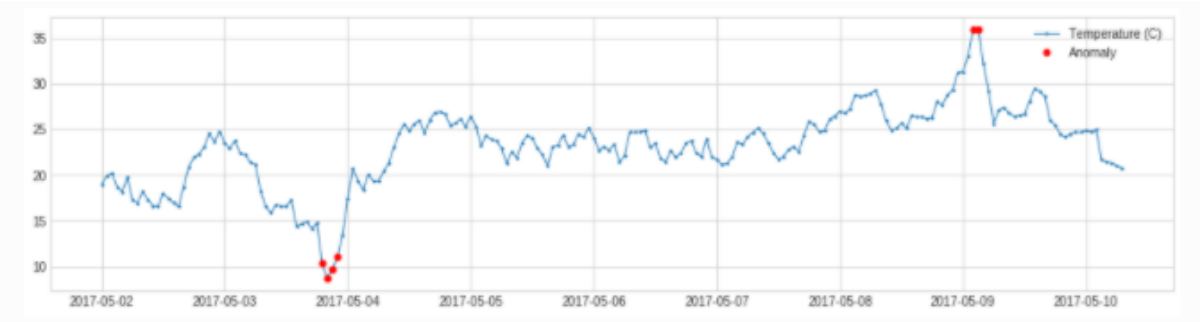

- 突变：Spike and Level Shift 异常的表现形式不是离群点，而是通过和临近点的比较，即突增或者突降。adtk提供`adtk.detector.PersistAD` 和 `adtk.detector.LevelShiftAD` 检测方法
  - PersistAD

```
adtk.detector.PersistAD(window=1, c=3.0, side='both', min_periods=None, agg='median')
参数：
```

window：参考窗长度，可为int, str
c：分位距倍数，用于确定上下限范围
side：检测范围，为'positive'时检测突增，为'negative'时检测突降，为'both'时突增突降都检测
min_periods：参考窗中最小个数，小于此个数将会报异常，默认为None，表示每个时间点都得有值
agg：参考窗中的统计量计算方式，因为当前值是与参考窗中产生的统计量作比较，所以得将参考窗中的数据计算成统计量，默认'median'，表示去参考窗的中位值

原理：
用滑动窗口遍历历史数据，将窗口后的一位数据与参考窗中的统计量做差，得到一个新的时间序列s1;
计算s1的(Q1-c*IQR, Q3+c*IQR) 作为正常范围；
若当前值与它参考窗中的统计量之差，不在2中的正常范围内，视为异常。

调参：
window：越大，模型越不敏感，不容易被突刺干扰
c：越大，对于波动大的数据，正常范围放大较大，对于波动较小的数据，正常范围放大较小
min_periods：对缺失值的容忍程度，越大，越不允许有太多的缺失值
agg：统计量的聚合方式，跟统计量的特性有关，如 'median'不容易受极端值影响
总结：先计算一条新的时间序列，再用箱线图作异常检测

```
from adtk.detector import PersistAD
persist_ad = PersistAD(c=3.0, side='positive')
anomalies = persist_ad.fit_detect(s)
```

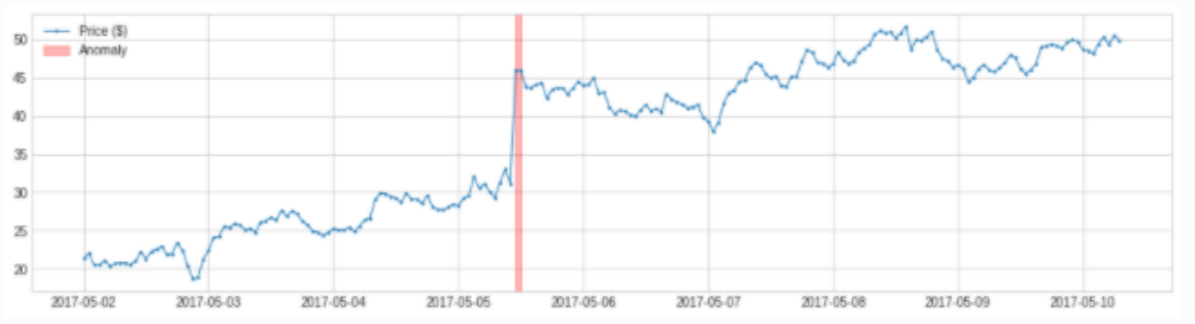

- LevelShiftAD

```
adtk.detector.LevelShiftAD(window, c=6.0, side='both',
min_periods=None)
```

参数：
window：支持(10,5)，表示使用两个相邻的滑动窗，左侧的窗中的中位值表示参考值，右侧窗中的中位值表示当前值
c：越大，对于波动大的数据，正常范围放大较大，对于波动较小的数据，正常范围放大较小，默认6.0
side：检测范围，为'positive'时检测突增，为'negative'时检测突降，为'both'时突增突降都检测
min_periods：参考窗中最小个数，小于此个数将会报异常，默认为None，表示每个时间

点都得有值

原理：
该模型用于检测突变情况，相比于PersistAD，其抗抖动能力较强，不容易出现误报

```
from adtk.detector import LevelShiftAD
level_shift_ad = LevelShiftAD(c=6.0, side='both', window=5)
anomalies = level_shift_ad.fit_detect(s)
```

- 季节性
  - adtk.detector.SeasonalAD

```
adtk.detector.SeasonalAD(freq=None, side='both', c=3.0, trend=False)
SeasonalAD主要是根据ClassicSeasonalDecomposition来处理，判断。
参数：
freq：季节性周期
c：越大，对于波动大的数据，正常范围放大较大，对于波动较小的数据，正常范围放大较小，默认6.0
side：检测范围，为'positive'时检测突增，为'negative'时检测突降，为'both'时突增突降都检测
trend： 是否考虑趋势
```

```
from adtk.detector import SeasonalAD
seasonal_ad = SeasonalAD(c=3.0, side="both")
anomalies = seasonal_ad.fit_detect(s)
plot(s, anomaly=anomalies, ts_markersize=1, anomaly_color='red',
anomaly_tag="marker", anomaly_markersize=2);
```

- pipe 组合算法

```
from adtk.pipe import Pipeline
steps = [
    ("deseasonal", ClassicSeasonalDecomposition()),
    ("quantile_ad", QuantileAD(high=0.995, low=0.005))
]
pipeline = Pipeline(steps)
anomalies = pipeline.fit_detect(s)
plot(s, anomaly=anomalies, ts_markersize=1, anomaly_markersize=2,
anomaly_tag="marker", anomaly_color='red');
```

6. 总结

本文介绍了时间序列异常检测的无监督算法工具包ADTK。ADTK提供了简单的异常检测算法和时间序列特征加工函数，希望对你有帮助。总结如下：

- adtk要求输入数据为datetimeIndex, `validate_series`来验证数据有效性，使得时间有序
- adtk单窗口和double窗口滑动，加工统计特征
- adtk分解时间序列的季节部分，获得时间序列的残差部分，可根据这个判断异常点
- adtk支持离群点、突变和季节性异常检测。通过`fit_detect` 获取异常点序列，也可以通过`Pipeline`联通多部异常检测算法